Amostragem e inferência estatística em registros de óbito infantil do SIM

Estudo estatístico – Porto Alegre

8 de novembro de 2026

Resumo

Este trabalho aplica amostragem aleatória simples, intervalos de confiança e testes de hipóteses a registros do Sistema de Informações sobre Mortalidade (SIM) de Porto Alegre. A população analítica foi definida como 1.776 registros não fetais com nascimento e óbito registrados por mês/ano e diferença de zero a 11 meses entre as competências. Dessa população foi sorteada, sem reposição, uma amostra aleatória simples de 316 registros, com confiança de 95%, erro planejado de cinco pontos percentuais, proporção conservadora de 0,5 e semente 2026. A análise incluiu dois testes para proporções e dois para médias, comparando resultados amostrais com parâmetros calculados diretamente na população. A proporção masculina amostral foi 55,06% e a idade média aproximada ao óbito foi 1,424 mês. As conclusões descrevem a composição dos registros elegíveis do arquivo; não estimam risco causal de mortalidade por sexo.

1 Fonte e contexto

A base é o conjunto SIM – Dados Abertos de Porto Alegre, publicado pela Secretaria Municipal de Saúde. O CSV recebido possui 135.548 linhas e 14 variáveis, com registros de óbitos entre 2011 e 2021.

O foco do exercício é a composição por sexo entre óbitos infantis. O arquivo não tem peso ao nascer e registra nascimento e óbito apenas por mês/ano. Assim, a idade ao óbito foi derivada como diferença entre as competências mensais, sem precisão em dias.

2 População e unidade amostral

A população analítica compreende registros não fetais com mês/ano válido de nascimento e de óbito, ano do óbito entre 2011 e 2021 e diferença não negativa menor que 12 meses entre as competências. O conjunto resultante tem **N = 1.776 registros**. A unidade amostral é uma linha elegível do CSV. Linhas integralmente repetidas foram mantidas, pois não houve validação da fonte que autorizasse removê-las; portanto, esta população representa registros no arquivo, não necessariamente indivíduos distintos.

As variáveis principais são sexo, idade aproximada ao óbito e ocorrência de nascimento e óbito na mesma competência. O sexo pode ser feminino, masculino ou não informado; as comparações por sexo usam somente os registros com sexo conhecido. A idade é uma diferença de mês/ano, em valores inteiros de zero a 11. Um valor zero significa que

nascimento e óbito foram registrados no mesmo mês/ano, não que a criança morreu antes de completar 28 dias.

3 Dimensionamento e seleção da amostra

Foram definidos nível de confiança de 95% ($Z = 1{,}96$), margem de erro de cinco pontos percentuais ($d = 0{,}05$), proporção de planejamento $p = 0{,}5$ e população finita $N = 1.776$. O tamanho inicial para população infinita foi:

$$n_0 = \frac{Z^2 p(1-p)}{d^2} = \frac{1{,}96^2 \cdot 0{,}5 \cdot 0{,}5}{0{,}05^2} = 384{,}16.$$

Aplicando a correção para população finita:

$$n = \left\lceil \frac{n_0}{1 + (n_0 - 1)/N} \right\rceil = 316.$$

Para $N = 1.776$, o valor antes do arredondamento é aproximadamente 315,99; arredondando para cima, obtém-se $n = 316$. O cálculo foi reproduzido no código do projeto. A calculadora USP/Bauru indicada no enunciado estava fora do ar em 09/11/2026; por isso, o valor foi conferido na calculadora de tamanho de amostra da SurveyMonkey (`https://pt.surveymonkey.com/learn/research-and-analysis/sample-size-calculator/`), com população 1.776, confiança de 95% e margem de erro de 5%, que também resulta em $n = 316$.

A amostra foi sorteada uma única vez, sem reposição, após ordenar pelo índice original da linha:

```
amostra = populacao.sort_values("indice_original").sample(
    n=316, replace=False, random_state=2026
)
```

A fração amostral é 17,79%. Como supera 10%, a correção para população finita foi incorporada aos erros-padrão e intervalos. O sorteio pode ser reproduzido pela semente 2026.

4 Descrição da população e da amostra

Medida	População ($N = 1.776$)	AAS ($n = 316$)
Idade média aproximada	1,476 mês	1,424 mês
Desvio-padrão da idade	2,426 meses	2,485 meses
Mediana da idade	0 mês	0 mês
Moda da idade aproximada	0 mês	0 mês
Proporção masculina (sexo conhecido)	54,89%	55,06%
Mesmo mês/ano (sexo conhecido)	52,74%	53,16%

Na população, a mediana e a moda iguais a zero não indicam ausência de cálculo: 939 dos 1.776 registros (52,87%) têm diferença de mês/ano igual a zero. Assim, pelo menos metade dos valores é zero, o que resulta em mediana zero; zero também é a categoria mais frequente, portanto é a moda. Na amostra, 168 de 316 registros (53,16%) têm valor

zero, e mediana e moda também são zero. Zero significa que nascimento e óbito foram registrados na mesma competência mensal, não uma idade exata em dias. Havia 971 registros masculinos e 798 femininos com sexo conhecido na população. As distribuições por sexo, faixas de idade aproximada (zero a um, dois a três, quatro a cinco e seis a 11 meses) e ocorrência na mesma competência são apresentadas nos Painéis 1 e 2. Diferenças entre as medidas amostrais e populacionais são esperadas pela variabilidade do sorteio.

5 Inferência estatística

Todos os testes foram definidos com significância de 5%, e os intervalos têm 95% de confiança. Parâmetros populacionais foram calculados sobre a população completa; estimativas, intervalos e testes inferenciais usam a AAS.

5.1 H1 – Uma proporção

Pergunta: os meninos têm, entre os óbitos infantis, participação maior do que entre os nascimentos?

Justificativa da referência: entre os 197.780 nascidos vivos de Porto Alegre registrados no SINASC de 2011 a 2021, 51,15% são meninos. Se o sexo não influenciasse o óbito infantil, a composição por sexo dos óbitos repetiria a dos nascimentos; uma proporção maior de meninos entre os óbitos indica sobremortalidade masculina relativa.

$$H_0 : \pi \leq 0{,}5115 \qquad H_1 : \pi > 0{,}5115.$$

Foi aplicado teste Z unilateral de uma proporção, com intervalo de Wald corrigido para população finita. A amostra teve 174 meninos em 316 registros com sexo conhecido, $P = 55{,}06\%$; o parâmetro populacional é $\pi = 54{,}89\%$. O IC 95% é de 50,09% a 60,04%, e o limite inferior unilateral de 95% é 50,89%; $Z = 1{,}536$ e $p = 0{,}0623$. Não se rejeita H_0 a 5%: a amostra aponta na direção de H_1, mas a evidência não é suficiente. Como a população está disponível, sabe-se que H_0 é falsa ($54{,}89\% > 51{,}15\%$). Trata-se de um **erro tipo II**: a diferença real, de 3,7 pontos percentuais, é pequena em relação ao erro-padrão de cerca de 2,5 pontos percentuais, e o teste tem pouco poder para detectá-la. Com a referência simplista de 50%, a mesma amostra levaria à rejeição ($Z = 1{,}986$; $p = 0{,}0235$), o que mostra como a escolha do valor de referência condiciona a conclusão.

5.2 H2 – Diferença de proporções

Pergunta: a proporção de registros no mesmo mês/ano do nascimento difere entre meninas e meninos?

$$H_0 : \pi_F - \pi_M = 0 \qquad H_1 : \pi_F - \pi_M \neq 0.$$

Foi aplicado teste Z bilateral para duas proporções e IC da diferença, com correção para população finita em cada grupo. Na amostra, as proporções foram 51,41% para meninas e 54,60% para meninos, com diferença $\pi_F - \pi_M = -3{,}19$ pontos percentuais. A diferença populacional é $-1{,}80$ ponto percentual. O IC 95% da diferença é de $-13{,}22$ a 6,84 pontos percentuais; $Z = -0{,}623$ e $p = 0{,}5332$. Não se rejeita H_0; a amostra não fornece evidência suficiente de diferença. O período é definido somente pela competência mensal e não deve ser interpretado como período neonatal exato.

5.3 H3 – Uma média

Pergunta: em média, o óbito infantil ocorre depois do primeiro mês de calendário após o nascimento?

Justificativa da referência: mais da metade dos registros tem diferença zero, o que indica forte concentração dos óbitos infantis logo após o nascimento. A referência $\mu_0 = 1$ mês representa um padrão em que os óbitos ocorrem, em média, até o mês seguinte ao nascimento.

$$H_0 : \mu \leq 1 \qquad H_1 : \mu > 1.$$

Foi aplicado teste t unilateral de uma amostra e IC t, ambos com correção para população finita. A média amostral é $\bar{x} = 1{,}424$ meses, ante parâmetro populacional $\mu = 1{,}476$ meses. O IC 95% é de 1,175 a 1,673 meses, e o limite inferior unilateral de 95% é 1,215 mês; $t(315) = 3{,}345$ e $p = 0{,}0005$. Rejeita-se H_0: apesar de a mediana e a moda serem zero, a cauda de óbitos entre 2 e 11 meses eleva a média acima de 1 mês. Na população, $\mu = 1{,}476 > 1$, então a decisão está correta. A referência de 1 mês é operacional, não um limite clínico.

5.4 H4 – Diferença de médias

Pergunta: a idade média aproximada ao óbito difere entre meninas e meninos?

$$H_0 : \mu_F - \mu_M = 0 \qquad H_1 : \mu_F - \mu_M \neq 0.$$

Foi aplicado teste t bilateral de Welch e IC da diferença, com correção para população finita em cada grupo. As médias amostrais foram 1,627 meses para meninas e 1,259 meses para meninos, diferença de 0,368 mês; a diferença populacional é 0,124 mês. O IC 95% é de $-0{,}142$ a 0,878 mês; $t(276{,}14) = 1{,}421$ e $p = 0{,}1563$. Não se rejeita H_0; não há evidência suficiente de diferença entre as médias aproximadas nesta amostra.

6 Comparação e interpretação

Os intervalos de confiança dos quatro testes contêm os parâmetros correspondentes calculados na população para esta AAS. Somente H3 rejeita a hipótese nula, e essa decisão está correta na população. H1, H2 e H4 não rejeitam. Em H1, a não rejeição é um erro tipo II com efeito real de interesse (3,7 pontos percentuais) e pouco poder do teste. Em H2 e H4, as diferenças populacionais ($-1{,}80$ ponto percentual e 0,124 mês) não são exatamente zero, de modo que a não rejeição também é formalmente um erro tipo II, mas sem relevância prática: em população finita, uma igualdade exata quase nunca ocorre. As diferenças entre estimativas pontuais e parâmetros populacionais ilustram a variabilidade amostral. Uma não rejeição não prova igualdade, e uma rejeição não implica relevância prática nem causalidade.

7 Limitações

1. Nascimento e óbito contêm apenas mês/ano; a idade é aproximada e pode classificar incorretamente registros próximos ao limite de 12 meses.

2. Mesma competência não identifica a duração exata entre nascimento e óbito.

3. Linhas integralmente repetidas foram mantidas; não foi possível confirmar se representam duplicação do arquivo ou eventos distintos.

4. O SIM contém somente registros de óbito. Os testes de proporção não estimam risco de morte por sexo; para isso seriam necessários denominadores de nascimentos compatíveis e desenho apropriado.

5. Os resultados se restringem à população analítica do arquivo e não devem ser generalizados para todas as crianças ou para relações causais.

8 Fonte, painéis e entrega

- Base original: SIM – Dados Abertos de Porto Alegre.
- Painel 1: população – link será inserido após publicação.
- Painel 2: amostra – link será inserido após publicação.
- Painel 3: inferência – link será inserido após publicação.
- Vídeo de apresentação (máximo de cinco minutos): link será inserido após publicação no YouTube.

Os arquivos com registros individuais permanecem locais. A aplicação utiliza o resumo de estatísticas agregadas, sem identificadores ou linhas individuais.